

数学建模实验报告

SVD 在图像压缩中的应用

姓名：莫亦非

学号：PB23151772

完成日期：2026 年 4 月 11 日

目录

1	奇异值分解 (SVD) 数学原理	3
1.1	矩阵构成	3
1.2	手动求解逻辑 (谱定理路径)	3
2	算法描述与实现逻辑：SVD 在图像压缩中的运用	4
2.1	图像数据预处理	4
2.2	核心算法的 Python 实现：高性能特征空间路径	4
2.3	低秩近似与截断策略	5
2.4	后处理与溢出控制	5
2.5	多维评估指标体系的构建	5
3	实验结果展示与分析	6
3.1	实验环境与测试样本说明	6
3.2	SVD 算法定量性能分析	7
3.2.1	视觉效果分析 (定性观察)	7
3.2.2	指标曲线分析	9
3.2.3	性能总结与评价	10
4	拓展实验与思考	10

4.1	算法原理简介	10
4.2	GUI 功能展示	11
4.3	量化指标分析	14
5	总结	14

摘要

本文重点探讨奇异值分解 (SVD) 在图像压缩任务中的数学原理与应用实践。实验核心在于利用线性代数中的谱定理, 通过构建协方差矩阵并进行特征值分解的路径, 自主实现了无需依赖库函数接口的 SVD 算法, 并基于奇异值能量分布特性实现了图像的低秩近似重构。通过搭建集成化的图形用户界面 (GUI), 本文定量分析了截断秩 (Rank) 对图像峰值信噪比 (PSNR)、结构相似性 (SSIM) 及压缩比 (CR) 的影响规律。此外, 作为性能验证的延伸, 本文对比了 SVD 与多种经典压缩算法在不同图像特征下的表现差异。实验结果验证了 SVD 在全局结构信息提取与冗余去除方面的高效性, 为其在低比特率重构任务中的应用提供了理论与实验支撑。

1 奇异值分解 (SVD) 数学原理

奇异值分解 (Singular Value Decomposition, SVD) 是线性代数中一种重要的矩阵对角化方法。对于任意一个矩阵 $A \in \mathbb{R}^{m \times n}$, 总存在以下形式的分解:

$$A = U \Sigma V^T$$

1.1 矩阵构成

- $U \in \mathbb{R}^{m \times m}$: 左奇异向量矩阵, 满足 $U^T U = I$, 其列向量是 AA^T 的特征向量。
- $V \in \mathbb{R}^{n \times n}$: 右奇异向量矩阵, 满足 $V^T V = I$, 其列向量是 $A^T A$ 的特征向量。
- $\Sigma \in \mathbb{R}^{m \times n}$: 奇异值矩阵, 仅在对角线上有非零元素 σ_i 。奇异值 σ_i 是 $A^T A$ (或 AA^T) 特征值的平方根, 且通常按降序排列: $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ (r 为矩阵的秩)。

1.2 手动求解逻辑 (谱定理路径)

本实验不直接调用现成的 `svd` 接口, 而是基于谱定理实现。其数学推导如下:

1. 计算对称矩阵 $M = A^T A$ 。
2. 对 M 进行特征分解: $M = V \Lambda V^T$, 得到特征值 λ_i 和特征向量 V 。
3. 计算奇异值 $\sigma_i = \sqrt{\lambda_i}$ 。
4. 根据 SVD 关系式 $Av_i = \sigma_i u_i$, 导出左奇异向量 $u_i = \frac{1}{\sigma_i} Av_i$ 。
5. 构造 U, Σ, V^T , 完成分解。

2 算法描述与实现逻辑：SVD 在图像压缩中的运用

本章详细描述如何将 SVD 理论应用于数字化图像，并阐述在 Python 环境下的具体实现细节与算法优化。

2.1 图像数据预处理

数字化图像在计算机中以张量 (*Tensor*) 形式存储。对于彩色图像 (*RGB*)，本实验采用以下处理流程：

1. **通道分离**：利用 *PIL* 库读取图像，将其拆分为 *R, G, B* 三个独立的二维像素矩阵。
2. **数值归一化**：将原始 $[0, 255]$ 的整数像素值转换为 $[0, 1]$ 之间的浮点数 (*float64*)。这一步不仅符合 *SVD* 的数学计算要求，且有效避免了后续矩阵乘法中的数值溢出问题。

2.2 核心算法的 Python 实现：高性能特征空间路径

根据实验要求，不直接调用现成的 *svd* 库函数。在 Python 实现中，本实验选择利用 *numpy.linalg.eigh* 接口。

实现选择的原因：

- **数学等价性**：由于 $A^T A$ 是半正定对称矩阵，其特征值分解 (*EVD*) 在数学上完美对应 *SVD* 的奇异值平方。
- **计算稳定性**：*eigh* 专门针对对称矩阵设计，调用了底层的 *LAPACK* (线性代数包) 库。相比于手写的幂迭代或 *QR* 算法，它在处理高分辨率矩阵时具有更高的数值精度和收敛速度。

推导流程代码化：

1. 计算 $M = A^T A$ 。
2. 调用 *eigh*(*M*) 获得特征值 λ 与特征向量 *V*。
3. 通过 $\sigma = \sqrt{\lambda}$ 构造奇异值向量。
4. 通过向量化运算 $U = (A \cdot V) / \sigma$ 导出左奇异向量矩阵，该步骤显著减少了 Python 层面的显式循环开销。

2.3 低秩近似与截断策略

压缩的本质是对信息的“有损截断”。

1. **奇异值截断**：根据用户在 GUI 中选择的截断秩 k ，提取 Σ 的前 k 个对角元素，以及 U 的前 k 列和 V^T 的前 k 行。
2. **矩阵重构**：执行矩阵乘积 $A_k = U_k \Sigma_k V_k^T$ 。
3. **动态截断演示**：通过 *Streamlit* 的 *slider* 控件实时调节 k 值。当 k 较小时，矩阵的低秩性质导致图像仅保留宏观轮廓；随着 k 增大，图像细节通过高阶奇异分量的叠加逐渐恢复。

2.4 后处理与溢出控制

由于 SVD 重构是浮点数运算，计算结果可能产生微小的数值偏差（如产生 -10^{-16} 或 255.0000001 这种无效像素值）。

- **截断操作 (*Clipping*)**：利用 `np.clip(A_k, 0, 255)` 将数值强行锁定在合法像素范围内。
- **类型转换**：将浮点矩阵重新映射为 `uint8` 格式，以恢复为标准的图像显示格式。

2.5 多维评估指标体系的构建

为了客观评价压缩质量，本实现集成了以下量化评估函数：

- **PSNR (峰值信噪比)**：通过计算压缩图像与原图的均方误差 (*MSE*) 的对数比，评估像素级的重建准确度。
- **SSIM (结构相似性)**：调用 `skimage.metrics.structural_similarity`，从亮度、对比度和结构三个独立维度评估图像的感知质量，使其更符合人类视觉主观感受。
- **CR (真实压缩比)**：通过 `np.savez_compressed` 模拟工业级二进制存储，计算原始图像字节数与压缩后实际存储字节数的比值，真实反映存储空间的节省程度。
- **性能监控**：引入 `time` 模块计算算法的全链路耗时，评估在交互式 GUI 下的实时处理能力。

3 实验结果展示与分析

3.1 实验环境与测试样本说明


- **软件环境**: Python 3.10+, *Streamlit*, *NumPy*, *Scikit-image*, *PyWavelets*。
- **测试样本**: 选取了具有不同统计特征的图像进行测试(例如: 具有丰富细节的 “*beauty*” 图、具有大面积平滑区域的 “*Peppers*” 图)。
- **硬件性能说明**: 在处理高分辨率图像时, 记录算法的响应时间以评估实时性。

3.2 SVD 算法定量性能分析


3.2.1 视觉效果分析（定性观察）




(a) 原始图



(b) $k = 1$



(c) $k = 5$



(d) $k = 10$



(e) $k = 25$



(f) $k = 40$



(g) $k = 50$



(h) $k = 100$



(i) $k = 150$

图 1: Peppers 图像在不同截断秩 k 下的 SVD 压缩效果对比

通过观察不同截断秩 k 下的重构图像，我们可以发现 SVD 压缩呈现出明显的“从抽象到精细”的阶梯式特征：

1. 极低秩阶段 ($k < 10$):

- 视觉表现：图像呈现出大面积的色块和模糊的阴影，细节完全丢失，但能够辨认出物体的大致方位和基础背景色。
- 数学解释：前几个奇异向量捕捉的是图像的直流分量 (DC) 和最宏观的全局结构。这证明了图像矩阵绝大部分的能量 ($Variance$) 被极少数奇异值所承载。

2. 中等秩阶段 ($k = 20 \sim 50$):

- 视觉表现：物体的边缘开始变得清晰，主要的线条和结构感已经基本恢复。但在高频区域（彩椒边缘）仍存在明显的“平滑感”或微小的伪影。
- 数学解释：这一阶段引入了中频奇异分量。图像的结构信息 (*Structural Information*) 已经基本补齐，这也是 SSIM 指标在这一区间迅速攀升的原因。

3. 高秩阶段 ($k > 100$):

- 视觉表现：图像在视觉上与原图几乎无异。微小的光影变化、精细纹理和高频噪声重新出现。
- 数学解释：此时重构矩阵包含了大量代表高频细节的小奇异值。虽然这些值在数值上很小，但它们决定了图像的锐度和真实感。

3.2.2 指标曲线分析

SVD 图像压缩性能深度分析 (peppers.jpg)




图 2: 指标扫描曲线

结合上述指标扫描曲线，可以从数值精度、视觉感知、存储代价及计算效率四个维度总结出以下核心规律：

- PSNR (重构质量) 的对数收敛特性：**红色曲线显示 PSNR 随 k 的增加呈现显著的对数增长规律。在 $k \in [1, 50]$ 区间内，PSNR 从 15dB 迅速跃升至 30dB 以上，有力证明了图像矩阵奇异值的能量高度聚集性。当 $k > 100$ 后，曲线斜率趋缓，说明高阶奇异分量主要携带微小细节与噪声，对降低均方误差 (MSE) 的边际贡献逐渐递减。
- SSIM (视觉感知) 的快速饱和效应：**蓝色曲线显示 SSIM 指数比 PSNR 更快进入饱和期。当 k 仅为 50 左右时，SSIM 已突破 0.85 临界点，在 $k = 125$ 后趋于稳定（接近 1.0）。这验证了人类视觉系统 (HVS) 感知的结构信息在低秩近似下即可得到有效恢复。实验证明，在工程应用中存在显著的“感知冗余”，无需追求极致的数值精度即可获得高质量的重构效果。

3. **真实压缩比 (CR) 的幂律衰减与“甜蜜点”选择：**绿色曲线揭示了真实存储成本随 k 增加呈典型的反比例 ($1/x$) 下降趋势。在极小秩下 CR 超过 250:1，但重构质量不可接受。通过对比发现，在 $k \in [30, 60]$ 区间，CR 维持在 15:1 至 25:1 之间，而此时 SSIM 已达 0.8 以上。该区间即为 SVD 压缩的“甜蜜点” (Sweet Spot)，实现了存储效率与视觉质量的最佳平衡。
4. **重构耗时的线性复杂度增量：**紫色曲线显示，在排除前置分解开销后，单次重构耗时随 k 的增大呈波动上升趋势（从 30ms 增长至约 85ms）。这反映了重构阶段矩阵乘法 $O(k \cdot m \cdot n)$ 的线性复杂度特征。曲线中的剧烈抖动反映了现代操作系统在毫秒级计算任务中的随机调度影响，但整体耗时始终保持在百毫秒以内的实时量级，证明了算法的工程可行性。

3.2.3 性能总结与评价

- **计算效率与工程可行性：**紫色曲线揭示了重构耗时随截断秩 k 呈现低斜率的线性增长规律。尽管计算量有所增加，但由于重构阶段的复杂度 $O(k \cdot m \cdot n)$ 远低于全量分解阶段的 $O(n^3)$ ，单次重构耗时仍稳健地控制在百毫秒量级。这证明了 SVD 算法在“分解一次，多次重构”的工程模式下（如视频流展示或交互式参数调节）具有极高的实时响应能力，具备在移动端等受限计算环境中应用的潜力。
- **算法本质与特征分级驱动：**SVD 在该任务中超越了单纯的“数据减法”，其本质是一种具备高度可解释性的**层级特征分级技术**。它通过奇异值的大小，将复杂的图像信号分解为“主干结构（低频能量）、中频细节、微小噪声（高频分量）”的有序序列。实验证明，SVD 在保证全局几何结构还原方面具有天然的数学优越性，这种按能量分布进行降维的特性，使其成为图像预处理与特征提取领域不可替代的基石算法。

4 拓展实验与思考

为进一步验证 SVD 的压缩特性，本实验引入了 PCA（主成分分析）、DWT（离散小波变换）及 DCT（离散余弦变换）三种经典算法作为对照组，并集成于统一的 GUI 评估平台中，以实现同一图像的标准化性能测试。

4.1 算法原理简介

- **PCA (主成分分析)：**通过对图像数据矩阵进行中心化处理，寻找方差最大的投影方向（即主成分）。在数学上，PCA 等价于中心化后的 SVD，旨在消除数据间的统计相关性。
- **DWT (离散小波变换)：**采用多分辨率分析策略，利用小波基对图像进行多尺度分解。它将图像分解为包含轮廓信息的低频分量和包含纹理细节的高频分量，通过阈值

法剔除不重要的细节。

- **DCT (离散余弦变换)**: 作为 JPEG 压缩的核心, 将空间域像素转换至频率域。图像信息主要集中于低频分量, 通过丢弃左下角的高频系数实现高效压缩。

4.2 GUI 功能展示

首先输入 `streamlit run app.py` 指令打开 GUI 页面, 内容如下图所示:



图 3: GUI 首页

左上角处可以选择是进行单独算法的使用还是多种算法统一压缩比进行效果对比。

首先展示单算法功能。图中可选类型有 **SVD**, **PCA**, **DWT**, **DCT** 四种算法, 每种算法都有对应的可调参数 (SVD 与 PCA 均为 K 值大小, DCT 可调整块数, DWT 可调整阈值大小)。




图 4: 单算法效果及性能展示

其次是多算法对比功能，选定图片，设置好预期压缩比，点击开启全量对比，稍作等待即可看见四种算法的对比图以及性能对比表（建议选择小图片以免等待过久）。




图 5: 多算法对比功能

4.3 量化指标分析




图 6: 率失真曲线

基于率失真曲线，对不同图像压缩算法进行量化分析，结论如下：

(1) 变换域算法在自然图像压缩中性能更优。在相同压缩比下，DCT 与 DWT 的 PSNR 明显高于 SVD 和 PCA，说明变换域方法能更高效地集中图像能量，在同等压缩率下具有更高的重构质量。

(2) SVD 与 PCA 压缩性能相近。二者的率失真曲线几乎重合，验证了 PCA 本质上是对数据中心化后进行 SVD 分解，在图像压缩中表现基本等价。

(3) 算法适用场景存在明显差异。DCT 在高压压缩比下仍能保持稳定的重构质量，适合通用图像压缩；SVD 在高压压缩比下性能下降较快，更适用于低压压缩比、强调结构保留的场景。

(4) 综合性能排序为：**DCT $\approx$ DWT > SVD $\approx$ PCA**，可作为工程中算法选择的依据。

5 总结

本文基于奇异值分解 (SVD) 实现了图像低秩近似压缩，并自主完成了不依赖库函数的 SVD 核心算法。通过构建 PSNR、SSIM、压缩比 CR 等指标，验证了 SVD 在图像结构信息提取与全局特征保留上的优势。实验表明，SVD 在截断秩 $k \in [30, 60]$ 区间可实现压缩效率与视觉质量的最佳平衡。与 DCT、DWT、PCA 对比后可知，SVD 更适合结构特征提取与低压压缩比场景，而 DCT/DWT 在高压压缩比下更具工业实用性。整体实验完整展示了 SVD 从数学原理到工程应用的全流程。